大数据可视化

课程案例

题目来源

- VAST Challenge：可视分析竞赛
- IEEE VIS：国际可视化年会
  - VAST（Visual Analytics Science and Technology）：可视分析科学与技术
  - InfoVis（Information Visualization）：信息可视化
  - SciVis（Scientific Visualization）：科学可视化

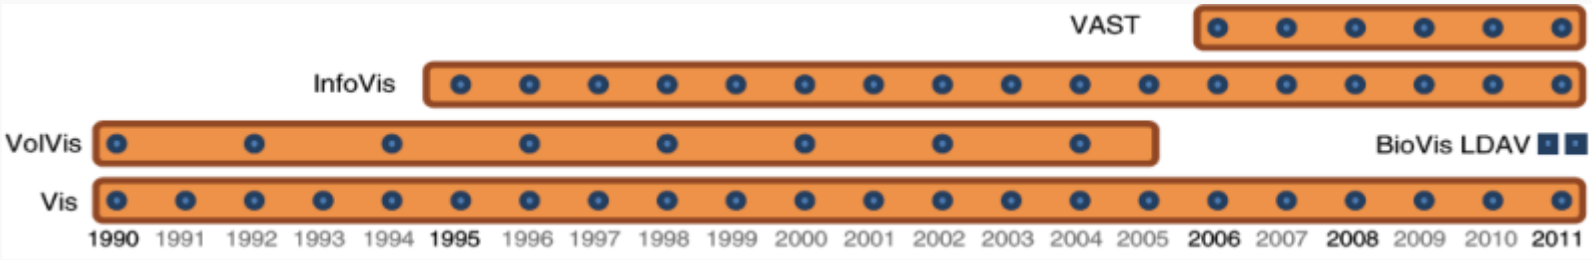

题目来源

- VAST Challenge
  - 可视化与可视分析是大数据时代最被关注的研究方向之一
  - IEEE VIS中的VAST Challenge是可视化与可视分析领域最重要、规模最大的竞赛
  - 它的竞赛题目覆盖可视分析最重要与前沿的研究领域，例如网络安全可视分析、时空数据可视分析与人际关系可视分析等等
  - 它从2006年举办至今，每年都有来自世界各地的高校、研究所与企业界的个人与团队参赛

案例背景

- 某国驻Flovania大使馆的信息安全组在网络日志中发现一些无法解释的非常规行为，他们要求大使馆反情报部门协助调查，发出间谍红色警报
- 一个雇员把机密信息泄露给犯罪组织

总任务和数据集

- 总任务
  - 分析间谍嫌疑人、同伙以及他们的犯罪证据

- 数据集
  - 任务一：网络日志和雇员登记信息（员工卡）
  - 任务二：雇员的社交网络
  - 任务三：Flovania周边的地理信息

任务一：雇员信息

- 60名雇员（employeeData），对大使馆设备有24h*7d的使用权，包括机密信息室
- 大使馆的办公室布局图（Embassy）
- 员工卡登记信息（proxLog）
  - 雇员编号ID，卡编号，在什么时间/地点刷卡
- 网络日志（IPLog3.5）
  - 登入的雇员编号，电脑的静态IP，目标地址，上传/下载量，端口号

任务一：数据样本

大使馆的办公室布局图（Embassy）：

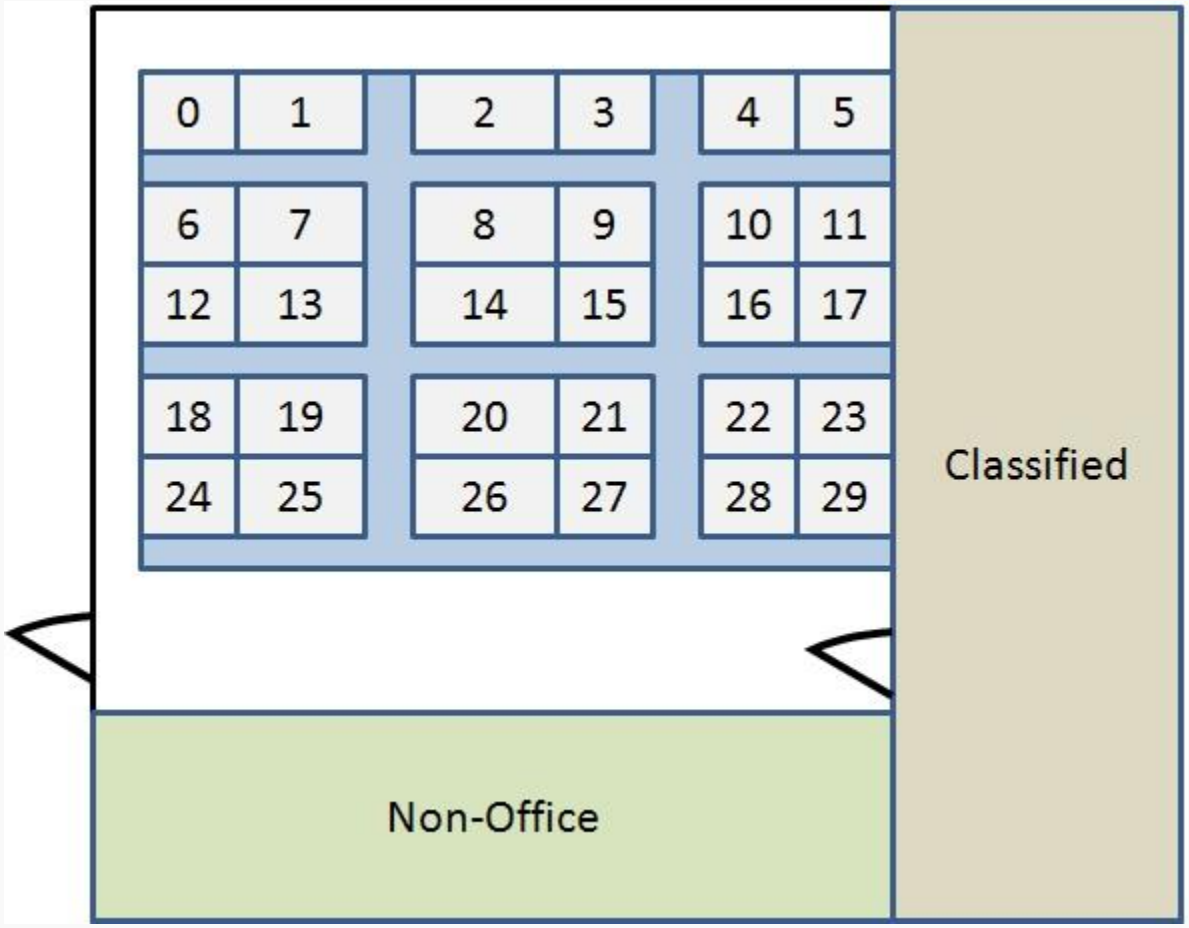

任务一：数据样本

雇员信息（employeeData）：

EmployeeID	IP	Office
0	37.170.100.0	0
1	37.170.100.1	0
2	37.170.100.2	1
3	37.170.100.3	1
4	37.170.100.4	2
5	37.170.100.5	2
6	37.170.100.6	3

雇员刷卡记录（proxLog）：
Prox-in：登记进入
Prox-out：登记离开
Classified：机密区

Datetime	ID	Type
2008-01-01T07:28	44	prox-in-building
2008-01-01T08:31	44	prox-in-classified
2008-01-01T09:23	38	prox-in-building
2008-01-01T09:56	44	prox-out-classified
2008-01-01T11:06	44	prox-in-building
2008-01-01T11:15	38	prox-in-classified
2008-01-01T12:14	38	prox-out-classified

雇员电脑网络日志（IPLog3.5）：

SourceIP	AccessTime	DestIP	Socket	ReqSize	RespSize
37.170.100.38	2008-01-01T09:40:29.276	37.170.100.200	80	7063	49591
37.170.100.38	2008-01-01T09:43:08.861	37.157.76.124	80	5171	434285
37.170.100.38	2008-01-01T09:47:41.282	37.170.30.250	25	32818	182798
37.170.100.38	2008-01-01T09:49:21.413	37.116.192.39	80	4455	46397
37.170.100.38	2008-01-01T09:50:12.995	10.24.74.254	80	5949	10166
37.170.100.38	2008-01-01T09:50:41.467	105.133.117.251	80	30999	56102
37.170.100.44	2008-01-01T09:57:17.588	37.170.100.200	80	3785	53246
37.170.100.44	2008-01-01T09:57:40.142	100.204.207.157	80	70031	10505

任务一

- 使用统计图可视化来回答问题：
  - 问题1：间谍使用哪台（些）电脑发送信息给他的联系人（同伙）
  - 问题2：描述间谍在大使馆办公室的位置与行为特征
  - 问题3：描述间谍发送机密信息的电脑使用特征，包括信息发送的时间/地点/方式

任务一：优秀可视化设计样例

- IP活动前100名记录
  - 交互：鼠标在右侧细矩阵内上下移动可对左侧单条记录进行高亮，右上角呈现具体信息

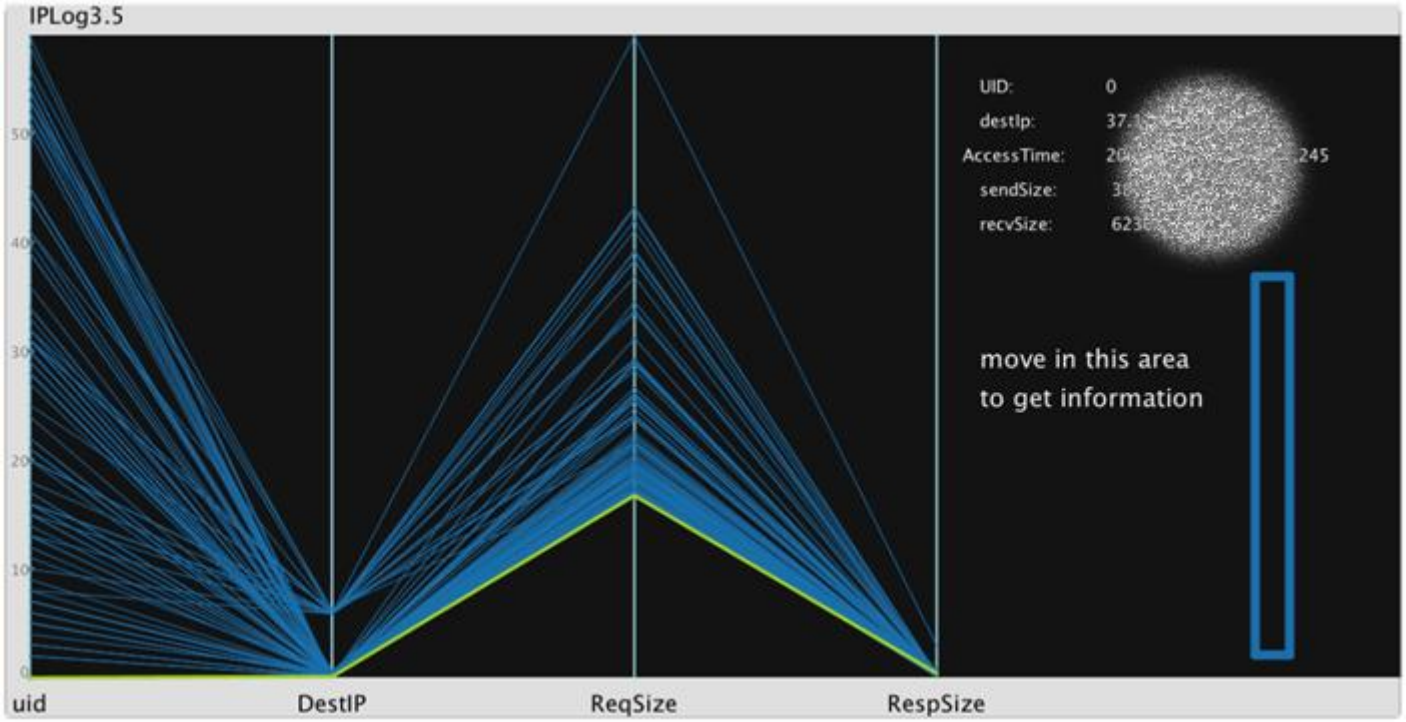

任务一：优秀可视化设计样例

- 灰色：时间轴，图中分为上下两个半圆，每个半圆表示从6:00至22:00；两个半圆的时间是对应的，以橘黄色线条对齐
- 绿色：一个员工一个月以来在各个时间段的活动频繁度

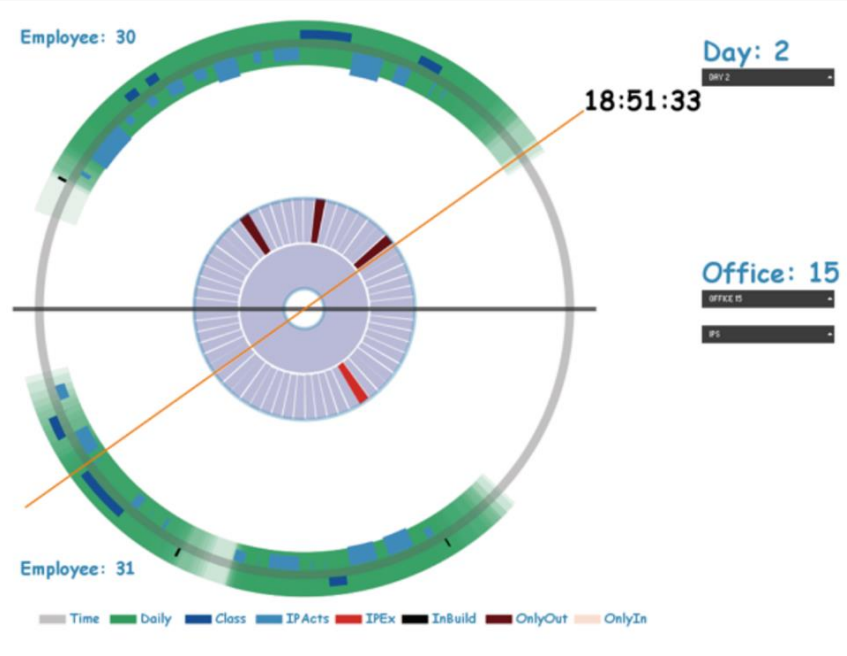

任务二：社交网络信息

- Flitter是一个在线社交工具，大使馆的雇员用来和同事、朋友联络（不一定是大使馆内部人员）
- Flitter不是实名制社交网络（Entities_Table）

ID	Name	Type
INT	STRING	STRING
1	@irvin	person
2	@rachel	person
3	@dykema	person

- Flitter提供了社交关系（Links_Table）

ID1	ID2
INT	INT
1	2
3	1
3	2

任务二：社交网络模式可能性

- 这一个雇员employee会和他的接头人handler通过社交网络联系
  - 1. 这个雇员大约有40个联系人，接头人有3个，接头人有30-40个联系人，接头人之间不互相联络
    - 2.A 接头人和犯罪组织之间还有一个中间人，代号Boris，Boris只和组织中一两个人联系（其中有他的老板）
    - 2.B 接头人和犯罪组织之间各有一个中间人，代号Boris，Morris和Horace，中间人只和组织中一两个人联系（其中有他们的老板）
  - 3. 中间人的老板boss代号Fearless Leader，他的Flitter联系人有上百个，包括其它国家的联系人

任务二：社交网络模式可能性

- 2.A：

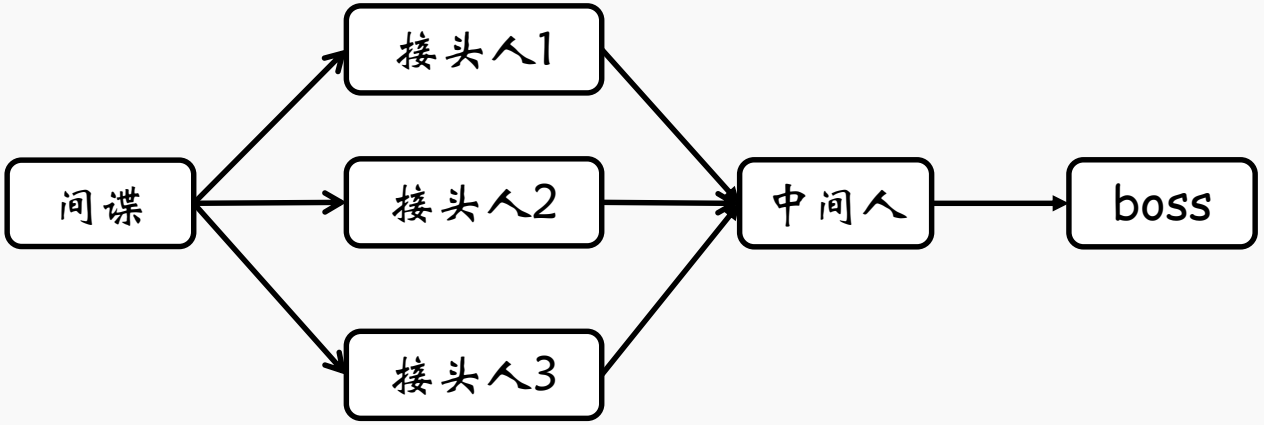

- 2.B：

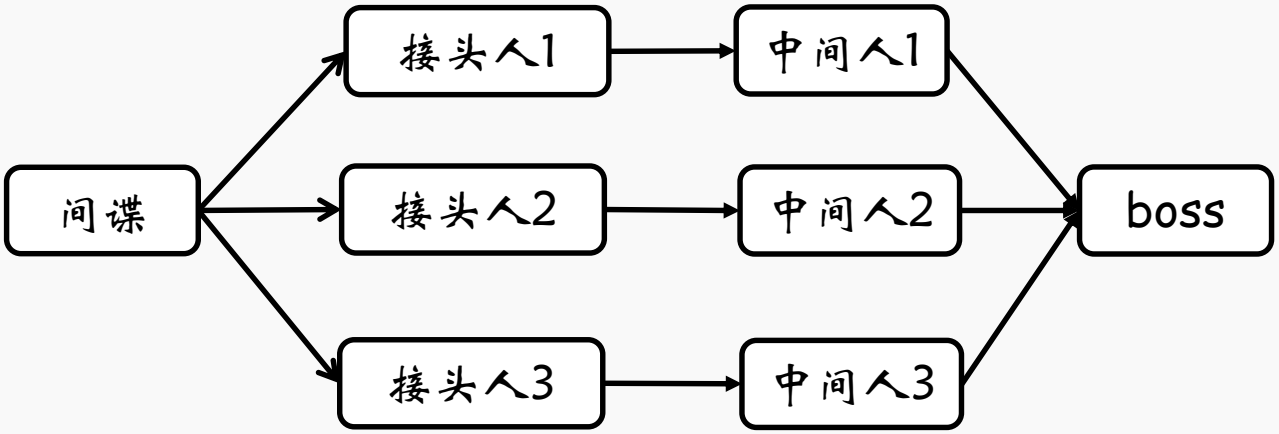

任务二

- 使用层次和网络数据可视化来回答问题：
  - 问题1：哪个可能性更大，1个中间人还是3个中间人？或者你发现还有其它模式？
  - 问题2：描述间谍、接头人、中间人、boss的社交关系
  - 问题3：描述机密信息的泄露网络，不需要提供关联的雇员ID，信息泄露网络涉及越少节点、越多关键人物越好

任务二：优秀可视化设计样例

- 社交网络关系图

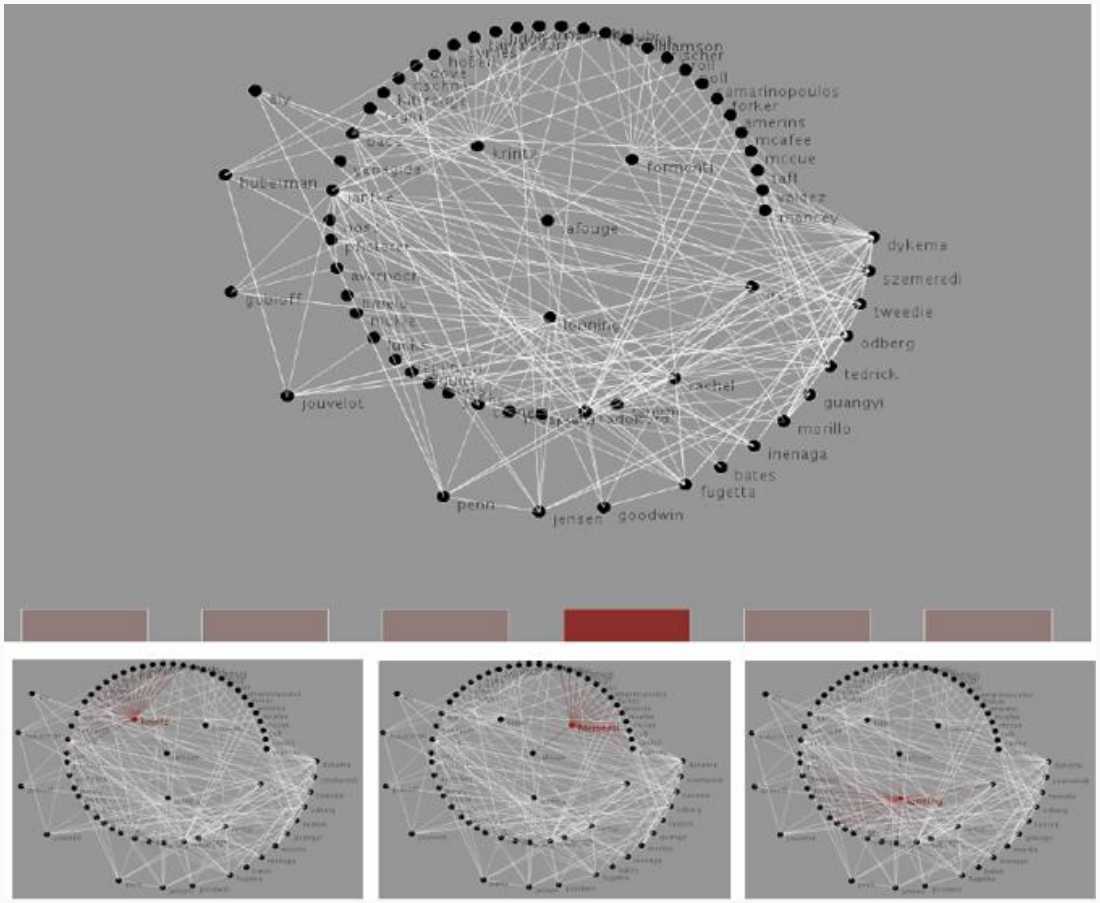

任务三：地理信息

- 关键人物的地理位置有限制（People-Cities）
  - 间谍和接头人在大城市
  - 中间人在附近的一个小城市
  - boss在一个更大的城市

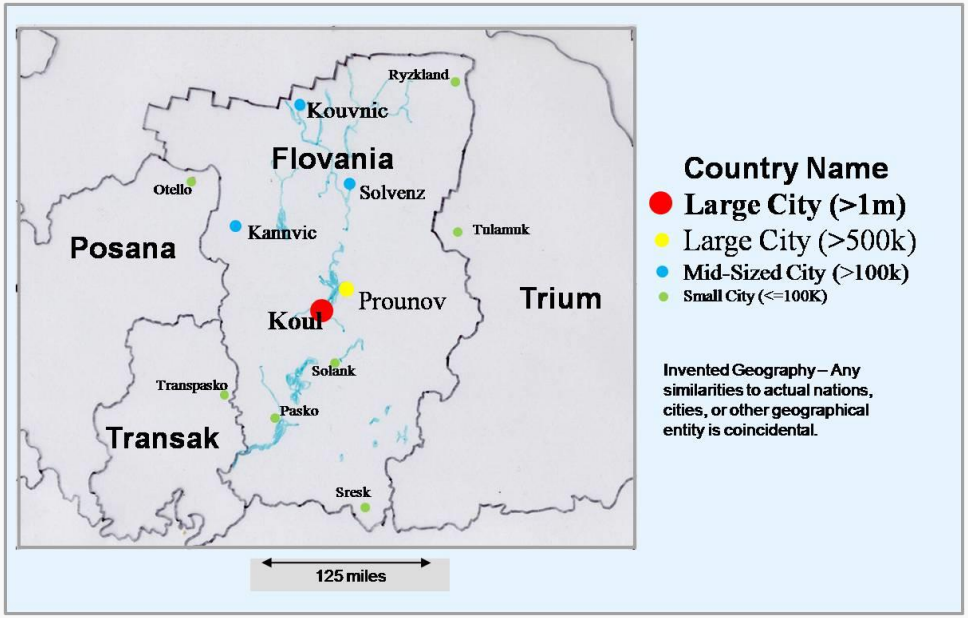

任务三

- 使用地理空间数据可视化来回答问题：
  - 问题1：描述Flitter用户是如何在城市间分布的
  - 问题2：Flovania的城市位置信息是否支持你对任务二的猜想？为什么？
  - 问题3：Flovania的哪个邻国和这次犯罪行为有关？为什么？

任务三：优秀可视化设计样例

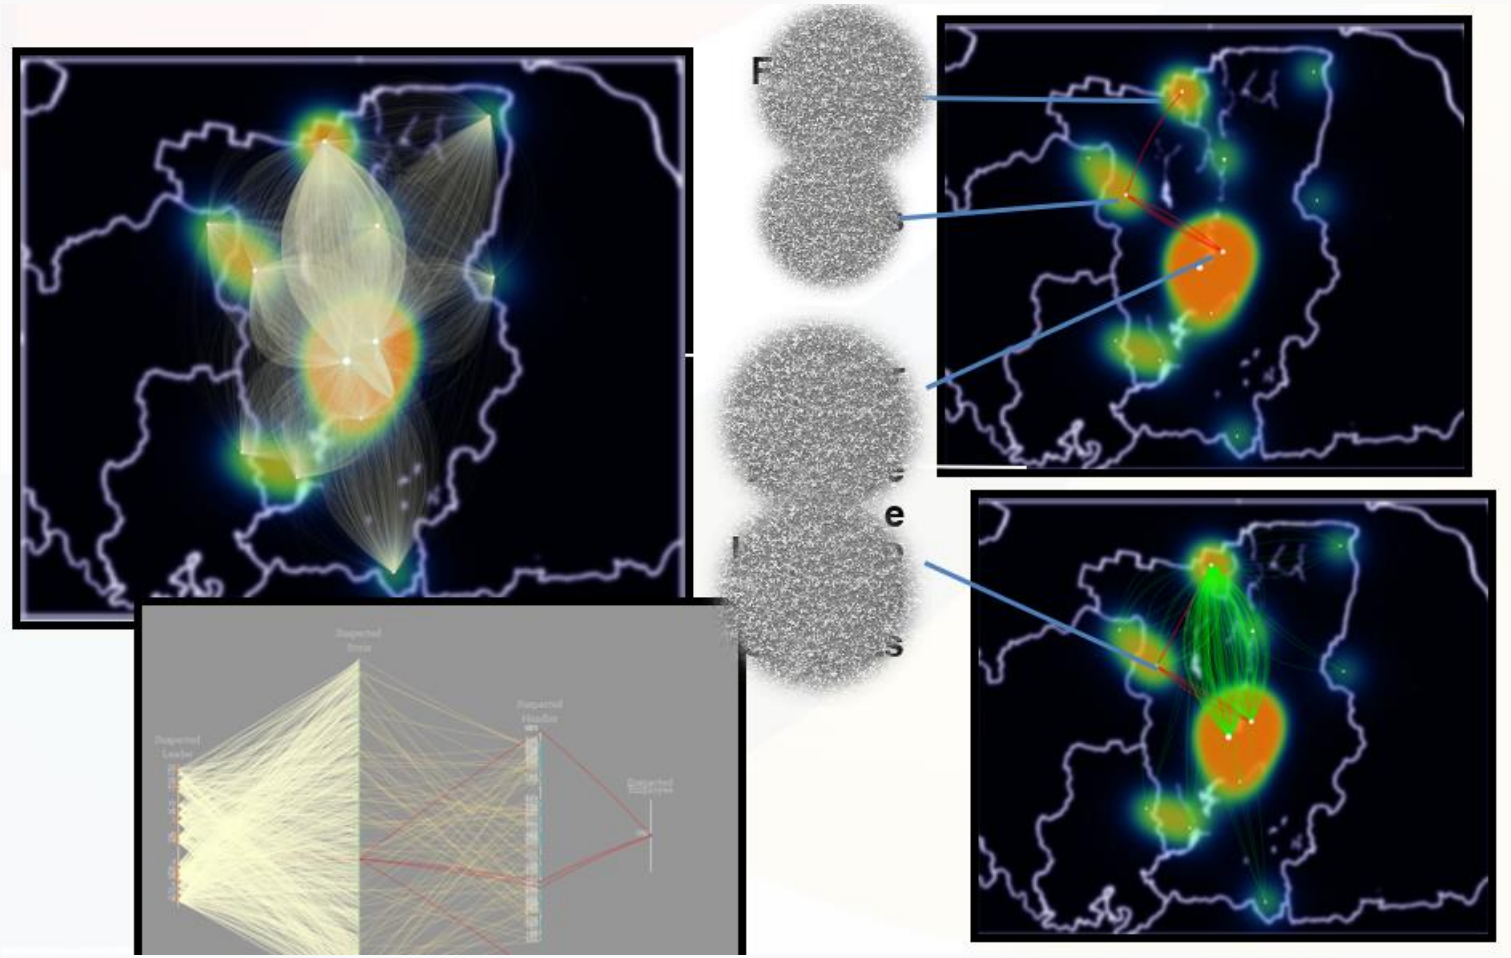

谢谢！